

Projet de synthèse : **Livrable 2**

Enseignants :

- Maria Alice Bertolim

Élèves :

- Matthieu Damien
- Florian Alzaix

Table des matières

1	Contexte	3
1.1	Problème de dataset	3
1.2	Nouveau sujet	3
2	Sources des données	4
3	Structure des fichiers	5
4	Structure des données	6
5	Méthode de travail	6
6	Une première analyse	7
6.1	Contexte et objectif	7
6.2	Données et périmètre expérimental	8
6.2.a	Dataset	8
6.2.b	Choix méthodologiques	8
6.2.c	Format des signaux	9
6.3	Features extraites	9
6.3.a	Features d'asymétrie	9
6.3.b	Features temporelles	9
6.3.c	Familles définies	10
6.4	Résultats	10
6.4.a	Classification PD vs CO – baseline	10
6.4.b	Régression UPDRSM – résultats et suspension	11
6.4.c	Vérification de l'effet protocole (étude)	11
6.4.d	Généralisation inter-études (LOSO)	12
6.4.e	Comparaison des familles de features	12
6.4.f	Importance des features	13
6.5	Interprétation	15
6.6	Limites et suite logique	16

1 Contexte

1.1 Problème de dataset

A la suite de complications avec les données des datasets précédents, problèmes de licences, chargement, format, labelling nous avons décidé de changer de sujet complètement.

Pour rentrer plus en détails. Le problème était en fait que ces datasets ont été fait pour faire des études biomécaniques complètes. Par conséquent, ils mettent l'accent plus sur les données de motion capture de GRF (Ground reaction force). Or pour traiter la problématique demandée il nous fallait les GRF, notamment la composante en Y pour déterminer la LDC du patient en question.

De plus afin d'établir une base comparable au réglage des orthoprothésistes il fallait des données statiques pour comparer la position de la LDC en statique et la comparer à celle de genoux de la même manière que les spécialistes. De telle manière nous aurions pu démontrer que les méthodes de réglage au ressenti sont plus ou moins pertinentes.

Ainsi il nous fallait donc des données de patients sains, et amputés, avec GRF en statique et en dynamique. Sans oublier que les données de GRF devaient être distinctes entre les deux pieds afin de pouvoir visualiser la ligne de charge par pied. Nous étions pas loin après quelques jours de galère mais l'obstacle final était la licence Vicon et l'incertitude d'obtenir des résultats certains avec les données proposées.

1.2 Nouveau sujet

Nous sommes donc parti sur un nouveau dataset, **Gait in Parkinson's Disease** pour étudier la maladie sous un nouvel angle.

Il reste néanmoins le besoin de déterminer la problématique exacte à traiter. Ce pourquoi nous avons proposé:

*Il s'agit d'étudier le dataset **Gait in Parkinson's Disease** à travers l'approche des heatmap, dans le but d'améliorer l'explicabilité des études précédentes et de proposer une méthode de diagnostic précoce de la maladie plus tôt et plus compréhensive des symptômes du patient.*

Pour expliquer plus en détail, le dataset contient en fait les données de 16 capteurs de pression, soit 8 sous chaque pied, et notre approche serait de reconstruire une séquence de heatmap/image de pression plantaire. Ce afin de pouvoir viser une meilleure explicabilité à la suite de l'entraînement d'un modèle.

Les études faites sur le dataset montrent déjà des scores d'accuracy très bons, allant jusqu'à 95% mais sans proposer des explications, en conservant l'effet boîte noire. C'est pourquoi nous allons nous concentrer sur une approche différente et plus explicable.

Note: Il est possible que les scores obtenus soient dus à un test set leakage, autant de raisons pour nous de proposer un modèle performant et explicable.

Néanmoins, cette méthode n'émane pas de nous, elle a déjà été menée sur d'autres datasets dans le même style et a porté ses fruits. En revanche, ce dataset n'a jamais été traité de cette manière (à sourcer à l'avenir pour être plus précis).

Important: Donc ce que nous proposons de nouveau $\Rightarrow$ GaitPDB natif + représentation heatmap anatomique + XAI capteur-résolu + interprétation clinique par zone plantaire

2 Sources des données

Les données du dataset sont mises en ligne sur le site PhysioNet, qui héberge habituellement des données pour la recherche dans le domaine du biomédical. Il est le résultat de la fusion entre trois études différentes :

- Ga (Yogev et al., 2005) : Étude montrant que la double tâche cognitive (marche + calcul mental) augmente drastiquement la variabilité de la marche chez les patients Parkinson mais pas chez les contrôles sains.
- Ju (Hausdorff et al., 2007) : Étude démontrant que la stimulation auditive rythmique (métronomie) améliore le rythme et réduit la variabilité de la marche sur tapis roulant chez les patients Parkinson.
- Si (Frenkel-Toledo et al., 2005) : Étude analysant comment la vitesse de marche sur tapis roulant affecte différemment la variabilité du stride time et du swing time chez les patients Parkinson.

3 Structure des fichiers

```

1  gait-in-parkinsons-disease-1.0.0/
2  ├── demographics.xlsx // Données par patients
3  ├── format.txt // Explication de la structure du dataset
4  ├── GaCo01_01.txt // Data ...
5  ├── GaCo01_02.txt
6  ├── ...
7  ├── GaCoXX_YY.txt
8  ├── GaPt03_01.txt
9  ├── GaPt03_02.txt
10 ├── ...
11 ├── GaPtXX_YY.txt
12 ├── JuCo01_01.txt
13 ├── JuCo01_02.txt
14 ├── ...
15 ├── JuCoXX_YY.txt
16 ├── JuPt01_01.txt
17 ├── JuPt01_02.txt
18 ├── ...
19 ├── JuPtXX_YY.txt
20 ├── SiCo01_01.txt
21 ├── SiCo01_02.txt
22 ├── ...
23 ├── SiCo30_YY.txt
24 ├── SiPt01_01.txt
25 ├── SiPt01_02.txt
26 ├── ...
27 └── SiPtXX_YY.txt

```

4 Structure des données

Chaque fichier contient 19 colonnes échantillonnées à 100 Hz : le temps (colonne 1), les forces de réaction verticale au sol (VGRF en Newton) pour 8 capteurs sous chaque pied (colonnes 2-9 pour le pied gauche, 10-17 pour le droit), et les forces totales sous chaque pied (colonnes 18-19).

Les 8 capteurs par semelle sont positionnés selon un système de coordonnées (X, Y) arbitraire permettant de calculer le centre de pression (COP) sous chaque pied : sous le pied gauche, les capteurs L1 à L8 sont placés de l'arrière (-800 mm) vers l'avant (800 mm) avec des positions latérales entre -300 et -700 mm ; symétriquement, les capteurs R1 à R8 du pied droit occupent les positions miroir (300 à 700 mm).

Les fichiers suivent la convention [Étude][Groupe][NuméroSujet]_[NuméroEssai].txt (exemple : GaCo01_02.txt), où le suffixe _10 indique une marche avec double tâche cognitive (soustractions sérielles de 7 pour l'étude Ga), _01 une marche normale, et les suffixes _02, _03, _04 représentent différentes conditions de marche propres à chaque étude (quoique non mentionnées dans le format.txt).

Les métadonnées cliniques associées incluent l'échelle Hoehn & Yahr (H&Y, stade 1-5), l'UPDRS total (sévérité symptomatique globale), l'UPDRS-M (sous-score moteur, partie III), et le TUG (temps en secondes pour se lever, marcher 3m, faire demi-tour et se rasseoir), bien que certaines valeurs puissent être manquantes selon les patients.

5 Méthode de travail

Grandes lignes draft:


- Création d'un sous dataset propre qui inclut la licence pour être carré.
- Entraînement et comparaison des modèles
- Explicabilité

Niveau du pré-traitement du dataset pour le moment:

- Déterminer ce que nous voulons classifier et régresser, possiblement le CO ou PD ainsi que le score de H&Y ou autre.
- Méthode de calcul de la heatmap sans introduire de biais.
 - Réflexion sur le format des heatmap, tenseur 3D avec dimension temporelle comme une vidéo un peu par exemple.
 - Réflexion sur la quantité de données pertinentes → durée 5s vs 30s par exemple.
 - Déterminer la profondeur de la heatmap mathématiquement afin de ne pas introduire de biais.
- Pré-traiter les variables afin de sélectionner les plus pertinentes en conservant le plus de données possibles malgré de nombreux NaN et un dataset qui est déjà petit (200Mo).

```
<class 'pandas.DataFrame'>
RangeIndex: 166 entries, 0 to 165
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
---  ---
0   ID                    166 non-null    str
1   Study                166 non-null    str
2   Group                166 non-null    str
3   Subjnum              166 non-null    int64
4   Gender               166 non-null    str
5   Age                  166 non-null    int64
6   Height               163 non-null    float64
7   Weight (kg)          163 non-null    float64
8   HoehnYahr            111 non-null    str
9   UPDRS                135 non-null    float64
10  UPDRSM               135 non-null    float64
11  TUAG                 153 non-null    str
12  Speed_01 (m/sec)     165 non-null    str
13  Speed_10             20 non-null     str
dtypes: float64(3), int64(2), str(9)
memory usage: 18.3 KB

<class 'pandas.DataFrame'>
Index: 93 entries, 2 to 109
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  ---
#   Column                Non-Null Count  Dtype
---  ---
0   Group                 93 non-null     int64
1   Subjnum               93 non-null     int64
2   Gender                93 non-null     int64
3   Age                   93 non-null     int64
4   Height                93 non-null     float64
5   Weight (kg)           93 non-null     float64
6   HoehnYahr             93 non-null     float64
7   UPDRS                 93 non-null     float64
8   UPDRSM                93 non-null     float64
9   TUAG                  93 non-null     float64
10  Speed_01 (m/sec)      93 non-null     float64
dtypes: float64(7), int64(4)
memory usage: 8.7 KB
```



6 Une première analyse

6.1 Contexte et objectif

L'objectif est de déterminer si des descripteurs agrégés extraits des signaux de pression plantaire permettent de distinguer des patients parkinsoniens (PD) de sujets contrôles (CO), et d'estimer grossièrement la sévérité motrice via le score UPDRSM.

Deux familles de features sont comparées : les features d'**asymétrie gauche/droite** et les **proxies temporels** (cadence, intervalles entre pics de charge).

6.2 Données et périmètre expérimental

6.2.a Dataset

Le dataset contient des enregistrements de pression plantaire (100 Hz, 16 capteurs par pied + total_L/total_R) collectés auprès de sujets parkinsoniens et contrôles, répartis sur trois études indépendantes.

Étude	CO	PD	Total	Protocole
Ga	18	29	47	Marche normale, dual-task
Ju	25	29	54	Marche normale + RAS (métronome)
Si	29	35	64	Marche normale
Total	72	93	165	

Tableau 6.1

6.2.b Choix méthodologiques

- **Session retenue** : 01 uniquement (marche normale, sans protocole secondaire). Une session = un sujet à ce stade.
- **Filtre** : `has_signal == True`. Le sujet `Juc010` (présent dans les métadonnées mais sans fichier signal) est exclu des modèles, conservé dans l'index pour traçabilité.
- **Biais protocole** : La variable `study` (Ga/Ju/Si) est tracée dans toutes les sorties pour permettre la détection d'un éventuel effet protocole.

- **Split train/test** : Séparation 75/25, stratifiée sur le groupe PD/CO. Avec session=01, 1 ligne = 1 sujet, ce qui garantit l'absence de fuite de données. Le même split est utilisé pour toutes les comparaisons de familles de features.

6.2.c Format des signaux

Chaque fichier `.txt` est un TSV sans en-tête, 19 colonnes, 100 Hz :

```
time  L1 L2 L3 L4 L5 L6 L7 L8  R1 R2 R3 R4 R5 R6 R7 R8  total_L  total_R
```

Les features sont calculées sur `total_L` et `total_R` (sommes des 8 capteurs par pied).

6.3 Features extraites

Les features sont calculées sur l'enregistrement entier, sans segmentation par cycle de marche. Chaque sujet produit un vecteur de features agrégées.

6.3.a Features d'asymétrie

Quantifie le déséquilibre gauche/droite dans la distribution de la pression plantaire.

Feature	Formule / Description
mean_asym	Moyenne de $(R-L) / (R+L+\epsilon)$ sur l'enregistrement
std_asym	Écart-type de l'indice d'asymétrie
mean_abs_diff	<code>`mean(</code>
diff_peak	<code>max(total_R) - max(total_L)</code>
diff_auc	<code>AUC(total_R) - AUC(total_L)</code>
ratio_auc_L_over_R	<code>AUC(total_L) / (AUC(total_R) + ϵ)</code>

Tableau 6.2

6.3.b Features temporelles

Basées sur la détection de pics de charge via `scipy.signal.find_peaks` (hauteur $\geq 20\%$ du maximum du signal, distance minimale $0.4\text{ s} = 40$ échantillons à 100 Hz). Fiables pour la marche normale en ligne droite (session 01) ; 0 NaN sur les 165 sujets.

Feature	Description
n_steps	Nombre total de pics (L + R)
cadence_spm	Cadence en steps/min
mean_interval_L	Intervalle moyen entre pics gauches (s)
cv_interval_L	Coefficient de variation des intervalles gauches
mean_interval_R	Intervalle moyen entre pics droits (s)
cv_interval_R	Coefficient de variation des intervalles droits

Tableau 6.3

6.3.c Familles définies

Famille	Features	Source
asymmetry_only	6 features d'asymétrie	§3.1
temporal_only	6 features temporelles	§3.2
combined	12 = asymétrie + temporel	§3.1 + §3.2
all_features	20 = combined + force brute (mean_L/R, std_L/R, auc_L/R, peak_L/R)	—

Tableau 6.4

6.4 Résultats

6.4.a Classification PD vs CO — baseline

Modèle entraîné sur les 20 features (`all_features`), split 75/25 stratifié.

Tâche	n_train	n_test	Accuracy	F1 weighted	ROC-AUC
PD vs CO	123	42	0.619	0.602	0.726

Tableau 6.5

6.4.b Régression UPDRSM — résultats et suspension

La régression a été testée sur les sujets PD avec UPDRSM disponible (n=91 ; 2 exclus pour valeur manquante). Les résultats sont reproduits sur 5 seeds différentes.

seed	n_test	MAE	RMSE	R ²	Spearman r	p
42	23	6.787	7.925	-0.195	-0.054	0.808
0	23	7.213	9.008	0.010	0.181	0.410
123	23	8.168	9.365	-0.827	-0.300	0.164
7	23	7.894	8.936	-0.140	-0.170	0.438
1	23	6.651	7.849	-0.127	-0.052	0.813
Moy.		7.3	8.6	-0.256	-0.079	

Tableau 6.6

R² systématiquement négatif ou nul, corrélation de Spearman non significative (p > 0.16 dans tous les cas). **La régression UPDRSM est suspendue** : les features agrégées sur l'enregistrement entier ne capturent pas la sévérité motrice à ce niveau de granularité.

6.4.c Vérification de l'effet protocole (étude)

Un classifieur logistique entraîné sur `study` (one-hot Ga/Ju/Si) comme unique prédicteur de PD/CO :

Accuracy	F1 weighted	ROC-AUC
0.571	0.416	0.553

Tableau 6.7

AUC $\approx$ 0.55 : la variable `study` seule est quasi aléatoire pour prédire PD/CO. Aucun biais de protocole majeur détecté.

6.4.d Généralisation inter-études (LOSO)

Validation leave-one-study-out : entraînement sur 2 études, test sur la 3ème. Modèle RF sur les 20 features.

Étude tenue hors entraînement	n_test	Accuracy	F1 weighted	ROC-AUC
Ga	47	0.638	0.640	0.628
Ju	54	0.630	0.628	0.685
Si	64	0.594	0.582	0.656

Tableau 6.8

L'AUC LOSO (0.63–0.68) est inférieure à l'AUC split aléatoire (0.726), ce qui indique un léger sur-apprentissage intra-étude. Le signal reste néanmoins généralisable.


6.4.e Comparaison des familles de features

Même split train/test pour toutes les familles (n_train=123, n_test=42).

Famille	N features	Accuracy	F1 weighted	ROC-AUC
temporal_only	6	0.548	0.546	0.618
asymmetry_only	6	0.667	0.659	0.752
combined	12	0.714	0.707	0.762
all_features	20	0.619	0.602	0.726

Tableau 6.9

Comparaison des familles de features



6.4.f Importance des features

Importance RF (MDI) sur le modèle entraîné avec toutes les features :

Rang	Feature	RF MDI	Famille
1	std_asym	0.153	Asymétrie
2	mean_asym	0.095	Asymétrie
3	diff_auc	0.059	Asymétrie
4	mean_R	0.059	Force brute
5	ratio_auc_L_over_R	0.058	Asymétrie
6	std_R	0.054	Force brute
7	auc_R	0.044	Force brute
8	mean_abs_diff	0.042	Asymétrie
9	mean_interval_L	0.041	Temporel
10	cv_interval_R	0.041	Temporel

Tableau 6.10


Importance par permutation (test set, 30 répétitions) – seules les features avec perm_mean > 0 apportent un signal positif :

Feature	perm_mean	±std	Famille
std_asym	+0.056	0.054	Asymétrie
diff_auc	+0.010	0.027	Asymétrie
peak_R	+0.007	0.030	Force brute
cv_interval_L	+0.007	0.025	Temporel
mean_abs_diff	+0.005	0.028	Asymétrie


Tableau 6.11

Importances RF et permutation

La matrice de corrélation des 12 features combined révèle les redondances internes :



Matrice de corrélation — combined features



Les features d'asymétrie sont fortement corrélées entre elles (mean_asym / std_asym / mean_abs_diff). Les features temporelles forment un second cluster cohérent (cadence_spm / n_steps / mean_interval_L / mean_interval_R). Les deux clusters sont faiblement corrélés, ce qui justifie leur complémentarité dans combined .

6.5 Interprétation

L'asymétrie gauche/droite est le signal discriminant principal. Avec 6 features d'asymétrie, le modèle atteint AUC=0.752, contre AUC=0.618 avec 6 features temporelles. La feature la plus informative est std_asym (variabilité de l'indice d'asymétrie au cours de la marche), cohérente avec la littérature sur l'asymétrie de la démarche parkinsonienne.

Les features temporelles seules sont insuffisantes à cette granularité (pas de segmentation par pas). Elles apportent cependant un gain marginal en complément de l'asymétrie : combined (+0.010 AUC vs asymmetry_only).

Ajouter les features de force brute dégrade la performance : all_features (20) est inférieur à combined (12) avec AUC=0.726 vs 0.762. Les features non-asymétriques (mean_L , std_L , auc_L , etc.) introduisent de la variance sans signal discriminant net.

L'effet protocole est contrôlé. La variable study seule produit AUC=0.553. La baisse d'AUC en LOSO (de 0.726 à 0.63-0.68) reflète une variabilité inter-protocole normale, pas un biais confondant.

6.6 Limites et suite logique

Limite actuelle	Impact	Suite possible
Features agrégées sur l'enregistrement entier (pas de segmentation par pas)	Features temporelles fragiles, UPDRSM non prédictible	Segmentation explicite par cycle de marche
COP (centre de pression) non exploité	Signal spatial non utilisé	Extraction de trajectoire COP L/R
Modèle unique (RF n=200)	Pas de comparaison de modèles	Ajouter LogisticRegression parcimonieuse, SVM
Session 01 uniquement	Périmètre réduit	Étendre aux sessions 02 et dual-task après validation
UPDRSM non prédictible avec features agrégées	Tâche de régression suspendue	À réouvrir avec features par pas

Tableau 6.12

La prochaine étape naturelle est la **sélection de features** (réduire à 5-6 features significatives) pour produire un modèle interprétable et testable sur des données externes, avant d'envisager des architectures plus complexes.