

Projet de synthèse : **Livrable 3**

Enseignants :

- Maria Alice Bertolim

Elèves :

- Matthieu Damien
- Florian Alzaix

Table des matières

1	Prétraitement des données	4
1.1	Prétraitement des metadonnées	4
1.2	Création des heatmap	4
1.2.a	Problème de taille de fichiers	7
1.2.b	Choix de H, W et de la durée de la vidéo	8
1.2.c	Robustesse	8
1.3	Conclusion sur le prétraitement	9
2	Premier traitement en machine learning	9
2.1	Validation et sélection de features — Refonte méthodologique	10
2.1.a	Problème identifié : fuite de sélection douce	10
2.1.b	Correction : sélection intra-CV	10
2.1.c	Features stables identifiées	10
2.1.d	Performances après correction	11
2.1.e	Généralisation inter-études (LOSO)	12
2.2	Comparaison d'algorithmes	12
2.3	Interprétabilité XAI et analyse SHAP multi-fold	13
2.3.a	Refonte de l'analyse XAI	13
2.3.b	Dashboard d'importance (MDI vs Permutation)	13
2.3.c	Analyse SHAP multi-fold	14
2.3.d	Triangulation des méthodes : signal robuste et zones de fragilité	15
2.4	Réduction de l'espace des features	15
2.4.a	Motivation	15
2.4.b	Trois configurations comparées	16
2.5	Exploration du continuum clinique — Fuzzy C-Means	16
2.5.a	Motivation et limites de l'approche précédente	16
2.5.b	Nouvelle implémentation	17
2.5.c	Résultats	17
2.5.d	Description des deux clusters	18
2.5.e	Sujets flous — expression du continuum clinique	18
2.6	Vue d'ensemble du pipeline et artefacts générés	19

2.6.a	Organisation des scripts	19
2.6.b	Fichiers CSV principaux	20
2.6.c	Figures principales	20
2.7	Discussion et limites	21
2.7.a	Ce que confirme cette itération	21
2.7.b	Limites persistantes	21
2.8	Perspectives	22

1 Prétraitement des données

Cette semaine nous avons commencé par réaliser un prétraitement des données. Notamment, la création des heatmap pour entraîner le modèle de deep learning par la suite.

1.1 Prétraitement des metadonnées

Premièrement, les metadonnées contenaient les scores H&Y et UPDRS ... Ces scores sont en fait directement corrélés au fait que le patient soit atteint de Parkinson ou pas. Par conséquent la première passe filtre toutes les lignes qui contiennent des NaN en ayant déjà retiré les colonnes de scores car fuite des labels.

Pour pouvoir entraîner le modèle nous avons aussi appliqué un mapping entre les labels et des nombres : Parkinson Disease (PD) $\Rightarrow$ 1 et Control patient (CO) $\Rightarrow$ 0.

Nous avons enregistré le tout dans le nouveau dataset dans un .csv.

1.2 Création des heatmap

Pour réaliser les heatmap nous avons lu les fichiers .txt qui contenaient les données des capteurs patient prétraité donc autrement les normes du vecteur GRF (Ground Reaction Force). Nous avons donc réalisé pour chaque ligne de chaque fichiers .txt de chaque patient, une heatmap de pression plantaire.


Autrement-dit nous avons essayé de représenter les données sans perte et sans augmentation artificielle pour faciliter l'apprentissage et surtout l'explicabilité par la suite. Ainsi, nous avons vu chaque capteurs comme un point dans le repère fourni dans le format .txt et l'amplitude de la force comme intensité sur ce point.

Dès lors, nous avons cherché les différents algorithmes qui permettent de faire quelque chose de similaire, nous avons trouvé `griddata()` qui était pas mal. Cependant elle interpolait seulement

dans les triangles internes ce qui est proche de la vérité mais dur à interpréter.

Nous sommes donc passé sur la fonction RBF (Radial Base Function) de scipy qui nous a permis de faire des points un peu comme des flous gaussiens sur l'image. L'amplitude de la gaussienne pour créer le flou étant défini par l'amplitude de la force GRF et l'écart-type par un paramètre estimé manuellement par nous.

Deux problèmes sont alors apparus. Le premier étant comme choisir cet écart-type/rayon? Car finalement si nous le choisissons à la main alors on peut introduire un biais mais aussi perdre de l'information. Nous sommes parti sur 9.5 pour faire des premiers tests car en apparence ça paraît pas mal. Néanmoins nous sommes conscients que ce n'est pas suffisant et qu'il faudrait plus de rigueur quant à la détermination de ce facteur.






Figure 1.2: Heatmap 2 avec un rayon de 6




Figure 1.3: Heatmap 3 avec un rayon de 8.5

Le second problème c'était l'orientation de la force. Vu que la GRF est censée être orientée et pas forcément perpendiculaire au sol, selon comment le patient appuie sur son pied elle peut être orientée pour propulser le patient. Donc finalement la forme circulaire du flou gaussien n'est peut-être pas la plus réaliste. Donc à voir si plus tard nous décidons de la remplacer par une forme un peu plus ovale ou même en forme d'aiguille orientée. La limite étant que nous n'avons pas l'orientation des GRF donc par conséquent nous ne pouvons pas faire quelque chose d'idéal.

1.2.a Problème de taille de fichiers

Nous avons enregistré les heatmaps en dur sur le disque au format .npy pour avoir directement les tenseurs disponibles afin de pouvoir entraîner plus vite. Seulement, le problème c'est que sans

compression alors la taille des fichiers explose.

Nous avons trouvé plusieurs solutions,

- Réduire la taille des fichiers en compressant en .npz
- Réduire la taille de stockage en quantifiant les heatmap notamment en passant de float32 à uint16 cela a réduit énormément la taille des fichiers.
- Réduire le nombre de frame un peu comme si on réduisait une vidéo.

Important: On peut parler de vidéo car finalement on a des tenseur de dimension (T, C, H, W), autrement-dit on a une succession d'image et par conséquent une vidéo. On a réalisé un script, `hm_video.py` pour recharger ces tenseurs et en faire une vidéo en .mp4 de manière à ce que soit plus visuel pour nous humains.

1.2.b Choix de H, W et de la durée de la vidéo

Les tailles H et W sont directement corrélées au facteur de taille sur le disque. C'est d'ailleurs le plus important car doubler ce H et W engendre x4 sur la taille du tenseur sur le disque. Cependant, augmenter H et W donne des images plus nettes. Nous avons donc cherché le juste milieu. Les modèles de CNN récent et autre backbone pré-entraînés supportent très souvent le format d'image C, H, W tel que C=3, H=224 et W=224. Nous sommes donc parti sur ces tailles standards. Même si au final c'est possiblement un peu grand pour le modèle.

Ensuite, les mesures ont été effectuées en 100Hz autrement-dit 100fps (frame par seconde). Ce qui veut dire que nous avons pour 5s de marche par exemple 500 frames. Donc l'idée, c'était de trouver une durée suffisante pour avoir le plus de pas possible et malgré tout conserver le moins de temps possible pour que les fichiers n'explorent pas et que le nouveau dataset exporté reste dans des tailles admissibles.

Nous nous sommes mis d'accord que entre 20s et 30s, c'était assez représentatif de la démarche du patient tout en restant dans des tailles raisonnables. Ce qui constitue environ 3000 images par patient, possiblement assez pour entraîner un modèle de deep, mais ? A voir !

1.2.c Robustesse

Le dataset met aussi à disposition des fichiers patient qui ne finissent pas que par _01 comme expliqué dans le rapport. Les _02 ce sont les démarches à différentes vitesses, ainsi que les _10 se sont les patients avec des calculs mentaux pendant l'entraînement. Ce type de données ne sont pas disponibles pour tous les patients ce qui est bien dommage. Mais à priori finetune le modèle sur ces quelques exemples nous permettrait d'avoir un modèle qui généralise plus facilement et par conséquent plus de robustesse. Hypothèse à tester.

1.3 Conclusion sur le prétraitement

Post prétraitement, il nous reste 158 patients avec chacun une heatmap, données de masse, taille, âge, genre et vitesse de marche _01. Nous avons retiré tous les biais et fait une première tentative de heatmap. Il ne reste plus qu'à tester nos hypothèses et se rendre compte que rien ne marche pour recommencer donc :) !

Prochaine étape l'entraînement des modèles de deep learning sur ce nouveau dataset.

2 Premier traitement en machine learning

Les images ne sont pas disponibles, manque de coordination, nous les inclurons dans le rapport final plutôt.

Au total, 33 features ont été extraites, réparties en plusieurs familles : **asymétrie gauche/droite** (indices d'asymétrie instantanée et au niveau du pas), **phases de marche** (stance, swing, leurs CVs bilatéraux), **cadence et quantité** (nombre de pas segmentés), et **force brute** (moyennes, écart-types, AUC, pics). L'AUC est normalisée par la durée de l'enregistrement (`np.trapezoid(L) / n_samples`) pour supprimer le confond lié aux enregistrements de longueur variable.

2.1 Validation et sélection de features — Refonte méthodologique

2.1.a Problème identifié : fuite de sélection douce

La version initiale du pipeline utilisait une liste hardcodée de features (dite `PARSIMONIOUS` , 6 features, puis `FINAL_FEATURES` , 19 features) sélectionnée de façon informelle en observant les résultats globaux. Ce mode de sélection introduit une **fuite de sélection douce** : les features choisies ont été influencées par l'ensemble des données, y compris le test, même si de façon indirecte.

2.1.b Correction : sélection intra-CV

La correction consiste à encapsuler la sélection dans un `Pipeline` `sklearn` :

```
1 Pipeline([
2     SelectFromModel(RF100, threshold="mean"), ← fitté sur le fold train un
3     RF200                                     ← classifieur final
4 ])
```

Le `SelectFromModel` ne voit jamais les données de test d'un fold. La sélection est répétée indépendamment pour chacun des 5 folds, ce qui permet de mesurer la **stabilité de sélection** : quelle fréquence chaque feature est-elle retenue à travers les folds ?

Le pool de départ est l'ensemble des 33 features (`ALL_CANDIDATE_FEATURES` = `FEATURE_COLS`). Aucune pré-sélection n'a lieu avant la boucle CV.

2.1.c Features stables identifiées

Après 5 folds de `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)` , les features sélectionnées dans au moins 60 % des folds sont les suivantes :

Feature	Fréquence de sélection	Famille
mean_asym	100 %	Asymétrie
asym_stance	100 %	Asymétrie

cv_swing_R	100 %	Variabilité
asym_swing	100 %	Asymétrie
cv_stance_L	80 %	Variabilité
cv_swing_L	60 %	Variabilité
asym_auc_steps	60 %	Asymétrie

Tableau 2.1

Ces 8 features constituent désormais **l’espace discriminant de référence** du projet. La fonction `load_stable_features(min_freq=0.6)` les retourne dynamiquement depuis `output/cv_feature_stability.csv`. Tous les modules en aval – XAI, SHAP, clustering – opèrent sur cet espace, ce qui garantit la cohérence globale du pipeline.

Vingt-cinq des 33 features candidates ont une fréquence de sélection nulle ou très faible ($\leq 20\%$), dont l’ensemble des features de force brute (`mean_L`, `mean_R`, `std_L`, `std_R`, `auc_L`, `auc_R`, `peak_L`, `peak_R`) et les intervalles temporels bruts (`mean_interval_L`, `mean_interval_R`, `cadence_spm`). Ce résultat confirme et formalise ce qui avait été observé empiriquement dans le rapport précédent.

![[../output/figures/validation/val_feature_selection_stability.png]]

2.1.d Performances après correction

Sur les 5 folds de validation intra-CV (1 ligne = 1 sujet, pas de fuite) :

Métrique	Moyenne	Écart-type
Accuracy	0.703	± 0.062
ROC-AUC	0.770	± 0.049
F1-Score	0.700	± 0.066

Tableau 2.2

![[../output/figures/validation/val_kfold_summary.png]]

Le ROC-AUC de 0.770 ± 0.049 est cohérent avec la performance de 0.726 obtenue en split unique dans le rapport précédent, mais sa mesure est désormais plus fiable : elle est moyennée sur 5 folds indépendants avec une sélection de features strictement apprise sur le train. La variabilité inter-folds (± 0.049) reflète la difficulté réelle de la tâche sur un jeu de 165 sujets.

Les courbes ROC et Precision-Recall ainsi que la matrice de confusion associées au split de diagnostic sont présentées ci-dessous :

![[../output/figures/validation/val_diagnostic_curves.png]]

2.1.e Généralisation inter-études (LOSO)

La validation Leave-One-Study-Out utilise le même pipeline intra-CV pour chaque partition train/test études. La robustesse inter-études est préservée :

![[../output/figures/validation/val_loso_robustness.png]]

2.2 Comparaison d'algorithmes

En parallèle de la validation principale par Random Forest, une comparaison multi-algorithmes a été conduite sur les mêmes 5 folds stratifiés, également sur le pool complet de 33 features avec sélection intra-CV.

Modèle	Accuracy	Balanced Accuracy	ROC-AUC
LogReg	0.739	0.736	0.816
SVC-RBF	0.752	0.746	0.811
LinearSVC	0.752	0.749	0.806
RF	0.758	0.747	0.802
GradBoost	0.691	0.677	0.780
XGBoost	0.691	0.677	0.759

Tableau 2.3

![[../output/figures/model_comparison/baseline_boxplot_roc-auc.png]]

Plusieurs observations ressortent. Les modèles linéaires (LogReg, LinearSVC) obtiennent des AUC légèrement supérieures au Random Forest, ce qui suggère que le signal discriminant dans l'espace des 8 features est en grande partie linéairement séparable — une propriété cohérente avec la nature géométrique des features d'asymétrie. À l'inverse, les modèles boostés (XGBoost, GradBoost) se montrent moins performants que les modèles plus simples sur ce jeu de données de taille modeste, probablement en raison d'un léger sur-apprentissage malgré la CV.

Le Random Forest reste le modèle de référence dans la suite du projet pour l'analyse d'interprétabilité, en raison de sa compatibilité native avec SHAP (TreeExplainer) et les importances MDI.

2.3 Interprétabilité XAI et analyse SHAP multi-fold

2.3.a Refonte de l'analyse XAI

L'analyse XAI initiale reposait sur un seul split train/test (~25 sujets en test), rendant les estimations d'importance instables. La version actuelle agrège les importances sur les 5 folds de validation : pour chaque fold, un RF est entraîné sur le fold train, et les importances MDI et par permutation sont calculées sur le fold test. La valeur finale pour chaque feature est la **moyenne des 5 estimations**, et l'écart-type inter-folds mesure la stabilité de l'explication.

2.3.b Dashboard d'importance (MDI vs Permutation)

![[../output/figures/xai/xai_importance_dashboard.png]]

Les importances MDI et par permutation divergent légèrement dans leur ordonnancement, ce qui est classique en présence de features corrélées (le MDI tend à distribuer l'importance entre features redondantes). Les deux méthodes s'accordent sur la dominance des features d'asymétrie.

![[../output/figures/xai/xai_family_importance.png]]

La famille **Asymétrie** est dominante, suivie de la **Variabilité**. Les features de cadence ou de quantité brute (nombre de pas) ont une importance presque nulle, ce qui confirme que le modèle exploite la qualité biomécanique de la marche plutôt que sa quantité.

2.3.c Analyse SHAP multi-fold

L'analyse SHAP a été ajoutée comme troisième estimateur d'importance. Un `shap.TreeExplainer` est instancié pour chaque fold ; les valeurs SHAP sont calculées **uniquement sur le fold de test** (pas de fuite). La valeur SHAP retenue par feature est la moyenne de `|SHAP|` sur l'ensemble des sujets et des folds, permettant une mesure de contribution absolue indépendante du signe.

Feature	SHAP moyen absolu	std inter-folds	Rang SHAP	Rang Perm
std_asym	0.094	0.028	1	1
asym_swing	0.071	0.018	2	2
asym_stance	0.066	0.012	3	—
cv_swing_R	0.058	0.017	4	—
mean_asym	0.041	0.015	5	—
cv_swing_L	0.028	0.008	6	—
asym_auc_steps	0.025	0.011	7	—
cv_stance_L	0.025	0.005	8	—

Tableau 2.4

![[../output/figures/shap/shap_mean_barplot.png]]

Le barplot horizontal représente la contribution SHAP moyenne de chaque feature (rouge = pousse vers la classe PD, bleu = pousse vers CO), avec les barres d'erreur représentant la variabilité inter-folds.

![[../output/figures/shap/shap_stability_by_feature.png]]

Ce boxplot illustre la distribution des contributions SHAP moyennes **par fold** : chaque point est la moyenne sur les sujets d'un fold de test. La dispersion verticale d'une feature mesure son instabilité d'interprétation. `std_asym` et `asym_swing` présentent une dispersion notable, ce qui appelle à la prudence dans leur interprétation individuelle.

![[../output/figures/shap/shap_group_heatmap.png]]

La heatmap par groupe confirme la cohérence clinique du modèle : les features asymétriques ont des valeurs SHAP positives pour les sujets PD et négatives pour les CO, alignées avec la littérature sur la dégradation bilatérale de la marche parkinsonienne.

2.3.d Triangulation des méthodes : signal robuste et zones de fragilité

La comparaison des trois estimateurs (MDI, permutation, SHAP) permet d'identifier trois catégories :

Signal robuste (accord des 3 méthodes) — `std_asym`, `asym_swing`, `asym_stance` : ces trois features figurent dans le top de chaque méthode. Elles reflètent la désynchronisation bilatérale caractéristique de la maladie de Parkinson : l'asymétrie de la phase oscillante (`asym_swing`) et de la phase d'appui (`asym_stance`), ainsi que la variabilité de l'indice d'asymétrie instantané (`std_asym`).

Features potentiellement redondantes — `mean_asym`, `asym_auc_steps` : leur importance par permutation est faible ou légèrement négative, suggérant qu'elles portent un signal similaire à d'autres features et que leur retrait individuel est compensé par les features corrélées.

Interprétations instables (`std_shap` élevé) — `std_asym` et `asym_swing` présentent les plus grandes variances SHAP inter-folds. Malgré leur rang élevé en importance absolue, leur contribution spécifique varie selon le sous-ensemble de sujets vu par chaque fold, ce qui invite à ne pas surinterpréter leur signe ou leur valeur exacte.

2.4 Réduction de l'espace des features

2.4.a Motivation

Bien que les 8 features stables soient non redondantes entre familles (asymétrie vs variabilité), plusieurs d’entre elles mesurent des aspects proches (par exemple `mean_asym` et `std_asym`, ou `cv_swing_L` et `cv_swing_R`). L’hypothèse testée est que remplacer des paires bilatérales par des proxies bilatéraux (moyennes ou différences) pourrait réduire la dimensionnalité sans dégrader la performance, tout en améliorant la stabilité des explications.

2.4.b Trois configurations comparées

Configuration	Nb. features	Balanced Acc	ROC-AUC
Complet (<code>FINAL_FEATURES</code> , 19)	19	0.747	0.802
Réduit bilatéral	13	0.741	0.801
Compact clinique	4	0.655	0.764

Tableau 2.5

![[../output/figures/validation/phase4_performance_comparison.png]]

La réduction bilatérale maintient des performances quasi-identiques au set complet (−0.006 en balanced accuracy, −0.001 en AUC), ce qui confirme la redondance latérale entre variables gauche et droite. En revanche, le set compact à 4 features perd significativement en performance (−0.092 en balanced accuracy), indiquant que certaines features asymétriques portent des informations complémentaires non capturées par un sous-ensemble trop restreint.

![[../output/figures/xai/phase4_xai_instability.png]]

2.5 Exploration du continuum clinique — Fuzzy C-Means

2.5.a Motivation et limites de l’approche précédente

Le rapport précédent présentait une analyse de clustering flou reposant sur un algorithme KMeans avec initialisation forcée (1 centre CO, 3 centres PD) et une fonction d’appartenance

ax maison. Cette approche avait plusieurs faiblesses : l'espace des features utilisé n'était pas aligné sur l'espace discriminant identifié par la CV, le nombre de clusters était fixé arbitrairement à 4, et la normalisation des appartenances via softmax ne correspond pas à la définition formelle du fuzzy c-means.

2.5.b Nouvelle implémentation

L'analyse a été entièrement refaite avec `scikit-fuzzy` (`skfuzzy.cmeans`), avec les caractéristiques suivantes :

- **Espace** : les 8 features stables de `load_stable_features(min_freq=0.6)` — même espace que le classifieur RF et l'analyse SHAP. Les centroides fuzzy sont ainsi directement comparables aux barplots d'importance.
- **Paramètre de fuzzification** : $m=2$ (valeur standard).
- **Sélection automatique de C_{opt}** : la Fuzzy Partition Coefficient (FPC) est calculée pour $C \in \{2, 3, 4, 5, 6\}$. Le C maximisant FPC est retenu.

La FPC mesure la netteté de la partition : $FPC=1$ correspond à une partition crisp parfaite, $FPC=1/C$ à une appartenance uniforme non-informative. Maximiser FPC revient à trouver le nombre de clusters qui structurent le mieux les données sans sur-partitionner.

2.5.c Résultats

C	FPC
2	0.576 ← optimal
3	0.400
4	0.308
5	0.250
6	0.211

Tableau 2.6

$C_{opt} = 2$ est retenu avec $FPC = 0.576$. La chute rapide de FPC au-delà de $C=2$ indique que les données ne supportent pas une partition plus fine : forcer davantage de clusters produirait des régions artificielles sans structure géométrique réelle.

2.5.d Description des deux clusters

Cluster	Sujets dominants	CO	PD	Feature saillante
0	107	63	44	CV Swing Time (L) basse
1	58	9	49	CV Swing Time ® élevée

Tableau 2.7

Le **Cluster 0** regroupe la majorité des sujets CO et une fraction des sujets PD présentant une variabilité de marche faible — profil biomécanique proche d’une marche régulière. Le **Cluster 1** concentre majoritairement les sujets PD avec une variabilité de la phase oscillante élevée des deux côtés, expression géométrique de la désynchronisation bilatérale identifiée par SHAP.

![[../output/figures/fuzzy_clustering/pca_projected_fuzzy.png]]

La projection PCA (2D) représente chaque sujet coloré par son cluster dominant, avec une opacité proportionnelle à son degré d’appartenance $u_{\max}$. Les cercles dorés entourent les **sujets flous** ($u_{\max} < 0.6$) : sujets situés dans les zones de recouvrement géométrique entre les deux clusters.

2.5.e Sujets flous — expression du continuum clinique

53 sujets sur 165 (32,1 %) présentent un degré d’appartenance maximal inférieur à 0.6, c’est-à-dire que leur profil biomécanique est réparti de manière significative entre les deux clusters. La valeur minimale de $u_{\max}$ observée est 0.501 (appartenance quasi-équivalente aux deux clusters).

![[../output/figures/fuzzy_clustering/soft_barchart_by_subject.png]]

Le barplot empilé montre les degrés d’appartenance pour un sous-ensemble de 20 sujets représentatifs (10 à forte appartenance nette, 10 à appartenance distribuée). Les sujets flous se concentrent en majorité dans les stades légers ou atypiques de la maladie : sujets PD en début d’évolution, ou sujets CO présentant une asymétrie naturelle plus prononcée.

![[../output/figures/fuzzy_clustering/centroids_fuzzy_barplot.png]]

Les centroides des deux clusters dans l’espace standardisé illustrent leur différenciation principale sur les variables de variabilité de swing (cv_swing_R , cv_swing_L) et d’asymétrie de l’AUC

(`asym_auc_steps`), cohérente avec les conclusions de l'analyse SHAP.

Il est essentiel de noter que ce clustering n'est pas un classifieur. La présence de 44 sujets PD dans le Cluster 0 ne constitue pas une erreur : elle reflète l'hétérogénéité clinique de la maladie de Parkinson (stades variés, phénotypes moteurs différents). Les clusters doivent être interprétés comme des **zones géométriques dans l'espace des features**, pas comme des groupes cliniques validés.

2.6 Vue d'ensemble du pipeline et artefacts générés

2.6.a Organisation des scripts

Script	Rôle
<code>main.py</code>	Orchestration complète (9 étapes), calcul unique de <code>build_feature_matrix</code>
<code>project/config.py</code>	Constantes globales (chemins, <code>RANDOM_STATE=42</code> , <code>SESSION="01"</code>)
<code>project/features.py</code>	Extraction des 33 features, normalisation AUC, segmentation pas
<code>project/validate.py</code>	Pipeline intra-CV (<code>SelectFromModel</code> → RF), LOSO, <code>load_stable_features</code>
<code>project/model_comparison.py</code>	Benchmarking multi-algorithmes sur les mêmes 5 folds
<code>project/xai.py</code>	XAI multi-fold (MDI, permutation), appel SHAP
<code>project/shap_analysis.py</code>	SHAP multi-fold (TreeExplainer, 5 folds, test uniquement)
<code>project/patient_clustering.py</code>	Clustering dur (K-Means, GMM, projections PCA/t-SNE)

project/fuzzy_clustering.py	Fuzzy C-Means avec sélection C_opt via FPC
project/feature_reduction.py	Comparaison de 3 jeux de features réduits

Tableau 2.8

2.6.b Fichiers CSV principaux

Fichier	Contenu
output/cv_validation_kfold.csv	Métriques par fold (accuracy, AUC, F1)
output/cv_feature_stability.csv	Fréquence de sélection des 33 features
output/feature_importance_metrics.csv	MDI, perm importance, direction PD/CO
output/shap_summary.csv	mean_shap, std_shap, mean_abs_shap, rang par feature
output/shap_importance_comparison.csv	Comparaison SHAP + perm + MDI fusionnée
output/u_final.csv	Degrés d'appartenance fuzzy (cluster_0, cluster_1) par sujet
output/df_clusters.csv	subject_id, group, u_max, cluster_max

Tableau 2.9

2.6.c Figures principales

```
1  output/figures/
2  |─ validation/
3  |   |─ val_kfold_summary.png           ← métriques CV par fold
4  |   |─ val_feature_selection_stability.png ← stabilité de sélection
5  |   |─ val_diagnostic_curves.png       ← ROC, PR, matrice de confusion
6  |   |─ val_loso_robustness.png         ← généralisation inter-études
7  |─ xai/
8  |   |─ xai_importance_dashboard.png    ← MDI vs perm, top 12
9  |   |─ xai_family_importance.png       ← importance par famille
```

10	— shap/	
11	— shap_mean_barplot.png	← SHAP moyen $\pm$ std inter-folds
12	— shap_stability_by_feature.png	← boxplot SHAP par fold
13	— shap_group_heatmap.png	← SHAP moyen PD vs CO
14	— fuzzy_clustering/	
15	— pca_projected_fuzzy.png	← PCA coloré par cluster + sujets f
16	— soft_barchart_by_subject.png	← barplot empilé par sujet
17	— centroids_fuzzy_barplot.png	← centroides dans espace 8D
18	— model_comparison/	
19	— baseline_boxplot_roc-auc.png	← distribution AUC par modèle
20	— baseline_barplot_accuracy.png	← accuracy comparative

2.7 Discussion et limites

2.7.a Ce que confirme cette itération

La refonte intra-CV confirme et formalise les intuitions du rapport précédent. Le signal discriminant est bien concentré sur les features d'asymétrie bilatérale et de variabilité de phase, et ceci de façon robuste : les 5 features sélectionnées dans 100 % des folds (`mean_asym` , `asym_stance` , `std_asym` , `cv_swing_R` , `asym_swing`) représentent le cœur stable du modèle, indépendamment du fold et des sujets inclus dans le train.

La concordance des trois estimateurs d'importance (MDI, permutation, SHAP) sur `std_asym` , `asym_swing` et `asym_stance` renforce la crédibilité de l'interprétation : ces trois features constituent un signal physiologiquement plausible, non un artefact de la méthode d'importance.

2.7.b Limites persistantes

Taille de l'échantillon. 165 sujets sur 5 folds impliquent des folds de test d'environ 33 sujets. Les estimations d'importance par permutation et de SHAP restent bruitées, comme en témoignent les `std_shap` non négligeables sur les premières features. Les conclusions interprétatives doivent être lues avec cette incertitude.

Agrégation sur l'enregistrement entier. Les features sont calculées sur la totalité du signal sans segmentation explicite par cycle de marche. Les informations dynamiques intra-cycle (freezing,

hésitations, asymétries transitoires) ne sont capturées qu'indirectement via les CVs de phase. Cela explique en partie le plafond de performance autour de AUC 0.77.

Absence d'exploitation des capteurs individuels. Le signal complet comporte 8×2 capteurs : seuls les signaux totaux (`total_L` , `total_R`) sont utilisés. Les patterns de distribution de pression au sein du pied (avant-pied vs talon, latéralisation), potentiellement riches en information clinique, ne sont pas exploités.

Régression UPDRSM suspendue. Comme documenté dans le rapport précédent, la régression de la sévérité motrice à partir de ces features agrégées ne produit pas de signal significatif (R^2 systématiquement négatif, corrélation de Spearman non significative). Cette tâche resterait à réouvrir avec une granularité plus fine (features par pas).

2.8 Perspectives

L'état actuel du pipeline représente une base solide pour une analyse exploratoire rigoureuse de la discrimination PD/CO à partir de signaux de pression plantaire en marche normale. Les directions naturelles pour la suite sont les suivantes.

Segmentation par cycle de marche. Plutôt que de passer par des heatmaps qui masquent une partie du signal, je propose de traiter directement le signal par pas, avec un clustering des pas et éventuellement un réseau de neurones pas-level, agrégé au niveau sujet (par exemple 70% des pas classés PD $\rightarrow$ sujet rapproché de PD); cela s'aligne avec la littérature sur l'analyse du cycle de marche, tout en gardant un lien direct avec le signal, les asymétries de pression, et la possibilité de capter la variabilité intra-enregistrement, la festination, le freezing, et potentiellement la régression UPDRSM, actuellement la principale limite de l'approche.

Exploitation des capteurs individuels. L'analyse en centre de pression (COP) ou en distribution par zone plantaire (avant-pied, milieu, talon) pourrait révéler des marqueurs spatiaux de la maladie complémentaires aux marqueurs temporels actuels.

Validation multi-session. L'extension aux sessions de dual-task ou de marche avec métronome (sessions 02 , 10 , protocole Ju) permettrait de tester la robustesse des features stables dans des conditions de charge cognitive ou d'assistance rythmique. Cette extension devrait se faire en préservant la séparation par sujet et en évitant la fuite entre sessions d'un même sujet.

Consolidation vers un modèle déployable. Les 5 features sélectionnées dans 100 % des folds forment un sous-ensemble naturellement parcimonieux, directement interprétable cliniquement. Un modèle logistique ou SVM linéaire sur ces 5 features uniquement serait potentiellement publiable et déployable sur données nouvelles sans recalibration complexe.

Exploration de la sévérité via le clustering flou. Le degré d'appartenance $u_{\max}$ au Cluster 1 (fort signal asymétrique) pourrait servir de proxy continu de sévérité, explorable en corrélation avec UPDRSM pour les sujets PD disposant d'un score. Cette analyse exploratoire ne remplacerait pas une régression supervisée, mais fournirait un premier éclairage non supervisé sur le lien entre structure géométrique des données et sévérité clinique.