

Classification de la marche parkinsonienne par analyse de pression plantaire

Matthieu Damien — ESEO E4 — Projet de Synthese 2026



GRANDE ÉCOLE D'INGÉNIEURS

Contexte et objectif

La maladie de Parkinson altere la marche de manière caractéristique : asymétrie gauche/droite, réduction de la cadence, traînée du pied. Ces modifications sont détectables dans les signaux de pression plantaire.

Objectif : Classifier automatiquement des sujets parkinsoniens (PD) et contrôles (CO) à partir de signaux de capteurs de pression plantaire, et identifier les marqueurs biomécaniques les plus discriminants.

Dataset : Gait in Parkinson's Disease v1.0.0 (PhysioNet) — **165 sujets** (93 PD, 72 CO), 16 capteurs par pied à 100 Hz, 3 études indépendantes (Ga, Ju, Si).

Methodologie

1. Segmentation et extraction de features

- **60 439 pas** segmentés à partir des signaux `total_L` / `total_R`
- Filtrage passe-bas Butterworth 10 Hz (zero-phase) pour le débruitage
- **45 features par pas** en 3 familles :
 - **Asymétrie et temporel** (15) : durée, peak force, asymétries intra-foulee

- **Capteurs individuels** (30) : distribution spatiale de la pression, ratios avant-pied/talon, entropie de Shannon

2. Architecture HybridCNN

Un CNN hybride a fusion tardive combine le **signal brut** (16 canaux x 150 samples) et les **45 features tabulaires** :

Branche Signal (CNN 1D) Conv1d 16→32→64→64 + BN + ReLU + Dropout → embedding (64)	Branche Tabulaire (MLP) Linear 45→32→32 + ReLU + Dropout → embedding (32)
↘	↙
Concat → Linear(96→2)	

- Data augmentation : scaling amplitude (x0.9–1.1) + bruit gaussien
- Classification au **niveau du pas** → agregation par majority vote au niveau sujet
- Validation : **StratifiedGroupKFold 5 folds** (pas de fuite inter-sujets)



3. Ensemble et optimisation

- Stacking RF + LogReg + HybridCNN → meta-classifieur LogReg (LOOCV sujet)
- Seuil de decision optimise par critere de Youden ($J = \text{Sensibilite} + \text{Specificite} - 1$)

Resultats

L'analyse opere au **niveau du pas** (60 439 pas segmentes) : chaque modele classifie individuellement chaque pas PD/CO, puis les predictions sont agregees par **majority vote** au niveau sujet.

Comparaison des modeles (classification par pas, agregation sujet)




Le HybridCNN domine tous les modeles avec une faible variance inter-folds.

Progression des performances (pas-level → agregation sujet) (pas besoin)

Phase	Meilleur modele	Balanced Acc	ROC-AUC
Baseline	FCM clustering	0.69	0.75
Phase 2 — CNN1D + features enrichies	CNN1D	0.66	0.75
Phase 3 — HybridCNN + capteurs	HybridCNN	0.77	0.87

Performance detaillee des modeles (pas besoin)


Comparaison baseline vs features enrichies + stacking — niveau sujet



Les modeles avec features capteurs (suffixe `_full`) dépassent systematiquement la cible de 0.75.

Courbes d'entrainement du HybridCNN (pas besoin)


HybridCNN — Courbes d'entrainement par fold



Convergence stable sur les 5 folds grace au dropout agressif (0.3 + 0.5) et a la data augmentation.

Vue d'ensemble — Stacking et ensembles (pas besoin)

Stacking vs modèles individuels — niveau sujet



L'Ensemble Final et le Stacking full franchissent la cible 0.75 sur toutes les metriques principales.

Contributions cles (pas forcément besoin)

Axe	Gain
Features par capteur individuel (30 features spatiales)	+18 pts LogReg (0.57 → 0.75) — gain le plus important
CNN hybride (signal + tabulaire)	+11 pts vs CNN1D (0.66 → 0.77)
Seuil Youden (0.62 vs 0.50)	+6.6 pts RF
Data augmentation	Stabilisation de l'entrainement (variance inter-folds reduite)

Conclusion et perspectives

- Le pipeline atteint **0.77 Balanced Accuracy** et **0.87 ROC-AUC** — un pouvoir discriminant eleve pour un dataset de 165 sujets
- Les **features par capteur** sont le levier principal : elles capturent la distribution spatiale de la pression (avant-pied/talon, asymetries par zone)
- Ces features offrent une **interpretabilite clinique directe** (SHAP, feature importance) : quels capteurs discriminent PD vs CO
- **Limite** : la taille du dataset (165 sujets, ~33 par fold de validation) contraint la generalisation
- **Perspective** : validation sur un dataset plus large (>500 sujets) et integration dans un outil d'aide au diagnostic precoce